

Documentação do Trabalho Prático: Máquina de Busca

José Vinícius de Lima Massarico
Matrícula: 2021037554

Programação e Desenvolvimento de Software II - Turma TW

Junho, 2023

1 Introdução

Neste trabalho, foi desenvolvido um programa para construir um índice invertido a partir de um conjunto de documentos e permitir a recuperação dos documentos relevantes com base em consultas de palavras-chave. O objetivo foi implementar um mecanismo eficiente de indexação e recuperação de documentos, considerando também a ordenação dos documentos com base em sua relevância.

2 Implementação

A implementação consiste em duas classes principais: Indexador e Documento. A classe Indexador é responsável pela construção do índice invertido e pela recuperação dos documentos relevantes. A classe Documento é utilizada para representar um documento do conjunto de documentos a ser indexado.

A indexação dos documentos é realizada pelo método `construirIndice`, que recebe como parâmetro o caminho para a pasta que contém os documentos a serem indexados. Durante a indexação, cada documento é processado individualmente. O programa percorre todos os arquivos presentes na pasta e para cada arquivo, lê seu conteúdo linha por linha.

Cada linha é então processada, separando as palavras presentes. Em seguida, cada palavra é normalizada utilizando o método `normalizarPalavra`. A normalização consiste em remover caracteres especiais e converter todas as letras para minúsculas. Esse processo garante que as palavras sejam tratadas de forma consistente, independentemente de letras maiúsculas ou caracteres especiais.

Após a normalização das palavras, o índice invertido é atualizado. O índice invertido é uma estrutura de dados do tipo mapa, que associa cada palavra a um mapa de documentos e suas ocorrências. Para cada palavra normalizada

encontrada, sua ocorrência no documento é registrada no mapa de documentos associado à palavra.

A recuperação dos documentos relevantes é realizada pelo método recuperarDocumentos, que recebe como parâmetro uma consulta de palavras-chave. A consulta é processada e as palavras são normalizadas da mesma forma que na indexação.

Para cada palavra da consulta, é verificado o mapa de documentos associado à palavra no índice invertido. Os documentos e suas ocorrências são armazenados em um mapa de documentos, e o número total de ocorrências em cada documento é calculado.

Após a contagem das ocorrências, os documentos são ordenados com base na relevância. Os documentos com maior número de ocorrências são considerados mais relevantes. Em caso de empate no número de ocorrências, é utilizada a ordem lexicográfica dos nomes dos documentos para desempate.

Por fim, os documentos ordenados são retornados como resultado da recuperação.

Essa implementação utiliza algoritmos simples, como a normalização de palavras e a contagem de ocorrências, além do uso de estruturas de dados adequadas, como mapas e vetores. O programa permite consultas flexíveis, em que várias palavras podem ser utilizadas como critério de busca.

2.1 Indexação de Documentos

A etapa de indexação de documentos é responsável por construir o índice invertido, que é uma estrutura de dados fundamental para realizar as consultas de forma eficiente. O índice invertido é uma representação em memória que associa cada palavra encontrada nos documentos a uma lista de documentos nos quais essa palavra ocorre, juntamente com a contagem de ocorrências.

O método construirIndice da classe Indexador é responsável por realizar a indexação dos documentos. Ele recebe como parâmetro o caminho para a pasta que contém os documentos a serem indexados. Para cada arquivo encontrado na pasta, o programa lê seu conteúdo linha por linha.

Em cada linha lida, as palavras são separadas e passam pelo processo de normalização, onde caracteres especiais são removidos e todas as letras são convertidas para minúsculas. Essa etapa garante que as palavras sejam tratadas de forma consistente, independentemente de letras maiúsculas, acentuação ou outros caracteres especiais.

Após a normalização das palavras, o índice invertido é atualizado. Para cada palavra normalizada encontrada, sua ocorrência no documento é registrada no mapa de documentos associado à palavra. O mapa de documentos armazena o nome do documento e o número de ocorrências da palavra nesse documento.

No final do processo de indexação, o índice invertido estará completo e pronto para ser utilizado na recuperação de documentos.

2.2 Recuperação de Documentos

A etapa de recuperação de documentos é responsável por receber uma consulta do usuário, composta por uma ou mais palavras-chave, e retornar os documentos relevantes que correspondem a essa consulta.

O método `recuperarDocumentos` da classe `Indexador` é responsável por realizar a recuperação dos documentos relevantes. Ele recebe como parâmetro uma string contendo a consulta do usuário.

A consulta é processada da mesma forma que na indexação, ou seja, as palavras são normalizadas, removendo caracteres especiais e convertendo todas as letras para minúsculas.

Para cada palavra da consulta, é verificado o mapa de documentos associado à palavra no índice invertido. Os documentos e suas ocorrências são armazenados em um mapa de documentos, e o número total de ocorrências em cada documento é calculado.

Após a contagem das ocorrências, os documentos são ordenados com base na relevância. A relevância é determinada pelo número de ocorrências de palavras-chave nos documentos. Os documentos com maior número de ocorrências são considerados mais relevantes. Em caso de empate no número de ocorrências, a ordem lexicográfica dos nomes dos documentos é utilizada para desempate.

Por fim, os documentos ordenados são retornados como resultado da recuperação, permitindo ao usuário visualizar os documentos mais relevantes de acordo com a consulta realizada.

3 Conclusão

Este trabalho apresentou a implementação de um programa em C++ para construção de um índice invertido e recuperação de documentos com base em consultas. Através da indexação dos documentos e utilização de estruturas de dados adequadas, como mapas e vetores, foi possível criar um mecanismo eficiente de busca e recuperação de documentos relevantes.

Durante a implementação, foram utilizados algoritmos simples, como a normalização de palavras e a contagem de ocorrências, além do uso de estruturas de dados adequadas para armazenar o índice invertido e os documentos relevantes. O programa permite uma consulta flexível, em que várias palavras podem ser utilizadas como critério de busca.

Em resumo, este trabalho possibilitou a aplicação de conceitos de processamento de linguagem natural e estruturas de dados em um programa para indexação e recuperação de documentos. A implementação oferece uma solução eficiente e escalável para lidar com grandes conjuntos de documentos.